

CAFE 面部表情识别项目 — 学习总结报告

日期: 2026-07-14

项目: FER 面部表情识别研究 (KMU-FED 数据集)

方法: CAFE (CLIP-Assisted Facial Expression Recognition)

一、学习内容总览

近期学习内容清单:

- ResNet 论文 (*Deep Residual Learning for Image Recognition*, He et al., 2015) 及其代码实现 (ResNet-18 34 50 101 134)
- CLIP 论文 (*Learning Transferable Visual Models From Natural Language Supervision*, Radford et al., 2021)
- 迁移学习的逻辑 (预训练 → 加载权重 `strict=False` → 冻结/微调策略)
- 交叉验证的逻辑 (KFold / LOSO 受试者独立评估)
- 损失函数复习 (交叉熵 CrossEntropyLoss、正则化损失)
- CNN 基础复习 (卷积层、BatchNorm、ReLU、MaxPool、全连接层)

二、代码研读情况

2.1 已详细阅读的代码

文件	行数	阅读行数	理解程度	关键内容
<code>models.py</code>	231	231 (100%)	★★★★	BasicBlock、ResNet、Mask、supervisor、Model
<code>CAFE_KMU-FED_train.py</code>	493	~180 (核心)	★★★★	训练循环、三损失组合、LOSO 划分
<code>config.py</code>	85	85 (100%)	★★★★	路径配置、超参数、表情映射

深入理解的核心逻辑:

- Model.forward()** — 双路前向传播: CLIP 冻结编码 + ResNet 可训练分支 → sigmoid 门控融合 → FC 分类
- supervisor()** — 作用在融合特征上的监督正则: loss_1 (掩码 CE) 防止捷径依赖, loss_2 (多样性) 鼓励均匀贡献
- Mask()** — 512 维分 7 chunk, 每 chunk 随机屏蔽 $10/73 \approx 14\%$, 每张图独立掩码
- train_one_fold()** — 单个划分的训练/验证循环, 含早停和最佳模型保存
- LOSO 划分** — `[(验证人, 其余11人列表, [验证人])] for 每个受试者`

2.2 跳过未查看的代码

文件/目录	行数	跳过原因
clip/clip.py	228	CLIP 模型加载器 — 作为黑盒使用，不修改
clip/model.py	432	ViT/Transformer 架构 — 本项目不修改 CLIP 内部
clip/simple_tokenizer.py	132	文本分词器 — 本项目只用图像编码，未使用
video.py	192	应用层推理脚本 — 不涉及模型原理
generate_video.py	—	工具脚本 — 图片合成视频
CAFE_KMU-FED_train.py 辅助部分	~200	parse_args、数据分布报告、TensorBoard、JSON 保存

三、三组实验对比分析

3.1 实验配置对比

配置项	实验 1	实验 2	实验 3
评估方法	10-Fold CV	LOSO (12 folds)	LOSO (12 folds)
类别数	7 (含空 NE 类)	6	6
人脸检测	YOLO (检测 person)	YOLO (检测 person)	Haar Cascade (检测人脸)
检测区域	整身 → 95.8% 图面积	整身 → 95.8% 图面积	人脸 → ~0.7% 图面积
训练 epoch	60	40	40
学习率	0.0002	0.0002	0.0002
模型架构	CAFE (ResNet+CLIP)	CAFE (ResNet+CLIP)	CAFE (ResNet+CLIP)

3.2 结果对比

指标	实验 1 (KFold+YOLO)	实验 2 (LOSO+YOLO)	实验 3 (LOSO+Haar)
平均准确率	71.66%	71.85%	62.66%
标准差	±18.01%	±11.72%	±12.09%
最高单折	—	—	83.00% (受试者 7)
最低单折	—	—	42.00% (受试者 11)
可靠性	✘ 数据泄漏风险	⚠ 检测错误	☑ 真实人脸

3.3 实验 3 详细结果 (LOSO + Haar Cascade)

Fold	受试者	验证图片数	最佳准确率	训练轮数	表情缺失情况
1	subject_1	84	59.52%	15	—
2	subject_2	120	63.33%	18	缺 DI, SA
3	subject_3	90	74.44%	15	表情完整 ☑
4	subject_4	60	48.33%	18	缺 AN, DI
5	subject_5	120	78.33%	18	表情完整 ☑
6	subject_6	84	66.67%	35	—
7	subject_7	100	83.00%	—	表情完整 ☑
8	subject_8	110	69.09%	—	—
9	subject_9	90	60.00%	—	—
10	subject_10	50	60.00%	—	—
11	subject_11	100	42.00%	—	缺 HA
12	subject_12	98	47.14%	—	缺 FE, SU

3.4 数据分析

3.4.1 实验 3 准确率下降的原因

实验 1/2 高达 71%+ 的准确率是**虚假的**——YOLO 检测的是"人"而非"脸", 裁剪区域覆盖全身 (平均 1541×1194 px, 占原图 95.8%) , 模型实际上看到了**衣服、背景、身体姿态**等非表情信息, 学到了错误的关联。

实验 3 只投喂**真实人脸区域** (约 115×115 px) , 模型被迫从表情本身做判断, 准确率 62.66% 是**更诚实**的评估。

3.4.2 受试者表情缺失与准确率的关系

差值：32.77 个百分点

4.3 数据集与评估协议

- **KMU-FED:** 1,106 张图, 12 人, 6 类表情, 无中性样本
 - **核心问题:** 8/12 受试者至少缺失一种表情, 表情分布不均衡 (DI 仅 120 张)
 - **LOSO 评估:** 每人轮流当验证集, 衡量"对新人泛化能力"
-

报告完成于 2026-07-14。