

今晚汇报讲稿 (2026-07-14)

基于 [PROJECT_COMPLETION_REPORT.md](#) 的口头汇报稿，面向师兄。

开场 (15秒)

师兄好，我汇报一下这周 CAFE 项目的学习进展。主要做了三件事：理论储备、源码通读、实验复现分析。

一、理论学习

ResNet 论文 (He et al., 2015)

ResNet 解决的核心问题是：网络越深反而训不动。不是过拟合，是梯度传不回去。

解决方案是残差连接——输出 = $F(x) + x$ ，学的是残差。加法在反向传播时不衰减梯度，所以 152 层也能训。

具体结构：四个 stage，每层两个 BasicBlock，总共 16 层卷积加首尾 = 18 层。个人手写了完整代码，和项目 models.py 的 ResNet 完全对应。

CLIP 论文 (Radford et al., 2021)

核心创新：用自然语言替代固定标签做监督。传统分类需要提前定好类别，CLIP 不用——4 亿个图文对训练，图像编码器和文本编码器各出一个 512 维向量，配对的拉近、不配对的推远。

在本项目里只用图像编码器，CLIP 冻结不动，相当于一个预训练好的“视觉语义词典”。ViT 内部结构未深入学习。

迁移学习

小数据集的通用解法——借大模型的底层特征。

本项目两个预训练模型策略不同：ResNet-18 在人脸识别数据集上预训过，用 `strict=False` 加载后继续训练；CLIP 完全冻结，不更新权重。

交叉验证

12 个人用 LOSO——每人轮流当一次验证集，剩下 11 个人训练。

和 KFold 的关键区别：KFold 可能把同一人的不同照片分到训练和验证，模型其实在“认人”而不是“识表情”。LOSO 保证验证集的人训练集完全没见过，测的是真实泛化能力。

损失函数 & CNN 基础

- 交叉熵 (CrossEntropyLoss) ——分类任务标准损失。本项目三损失组合：`1.0×CE + 1.5×Masked_CE + 5.0×Diversity`
- CNN 基础组件复习——Conv2d、BatchNorm、ReLU、MaxPool、全连接层

二、代码研读

三个核心文件全读完了：

文件	阅读程度	关键内容
models.py	231行全部	BasicBlock、ResNet、Mask、supervisor、Model
train.py	核心部分	训练循环、三损失组合、LOSO 划分
config.py	85行全部	路径配置、超参数、表情映射

跳过的：clip/ 文件夹（CLIP 黑盒使用，不修改）、video.py（应用层脚本）、generate_video.py（工具脚本）。

三、三组实验结果

对比总览

	实验1	实验2	实验3
方法	KFold+YOLO	LOSO+YOLO	LOSO+Haar
准确率	71.66%	71.85%	62.66%
标准差	±18.01%	±11.72%	±12.09%
可信度	✗	⚠	☑

三个关键发现

- 前两组 71% 是虚高的。** YOLO 检测的是整个人，裁剪区域占画面 95.8%，模型看到的是衣服和背景，不是脸。
- 第三组 62.66% 是真实水平。** Haar Cascade 只投喂人脸区域（约 115×115px），模型从表情本身做判断。
- 表情缺失导致准确率崩塌。** 表情完整的人平均 78.59%，缺失 2 种表情的只有 45.82%，差 33 个百分点。

存在的问题

- 严重过拟合：训练准确率 90%+，验证 40-83%，差距 20-30 个百分点
- 数据集太小：1106 张图，12 人，8/12 的受试者至少缺失一种表情
- 监督分支（MC Loss）效果有限，从头到尾变化不大

收尾（15秒）

目前理论知识 + 源码通读 + 实验分析都完成了，CAFE 整体流程基本掌握。详细数据和代码索引在 PROJECT_COMPLETION_REPORT.md 里。下一步方向还请师兄指导。